



VNPT AI
DEFINE THE FUTURE

Vietnamese Student HackAlthon 2026 - Bảng C Innovator

VietMind MCQ

AI Agent giải trắc nghiệm tiếng Việt
bằng suy luận thích ứng

Đội Cow 🐮: Lê Quang Minh, Nguyễn Ngô Thảo Uyên, Nguyễn Minh Việt

Giới Thiệu Nhóm

Lê Quang Minh



Đại học Denison

Thành viên nhóm

Nguyễn Ngô Thảo Uyên



Đại học Denison

Thành viên nhóm

Nguyễn Minh Việt



Đại học Denison

Thành viên nhóm

Tóm Tắt Nhanh Phương Pháp

85.96%

Kết quả public test (v03_gamma), được kiểm chứng trên bảng xếp hạng công khai Vòng 1; được chọn vì cân bằng tốt giữa độ chính xác, tốc độ và sự ổn định.



Một mô hình LLM mở duy nhất $\leq 5B$

Được vận hành bởi **Qwen/Qwen3.5-4B** mà không sử dụng RAG, API bên ngoài, hay kỹ thuật tinh chỉnh.



Lập luận thích ứng + chọn đáp án có kiểm soát

Mỗi câu hỏi được định tuyến theo nhóm; câu khó được suy luận nhiều lượt, sau đó hệ thống ép kết quả về một đáp án hợp lệ trước khi xuất file.



Docker container ngoại tuyến

Thực thi khép kín, không phụ thuộc mạng, đảm bảo an toàn cho giới hạn nghiêm ngặt 16 GB VRAM, và luôn cố gắng ghi file nộp hợp lệ.



Nâng cấp cho vòng cuối

Dựa theo nhận xét của BTC, hệ thống được cải tiến để giúp ngăn cản việc tràn bộ nhớ và bổ sung cơ chế logging để theo dõi route và thời gian chạy của từng câu.

1. Bài Toán và Nhận Định Chính

Một học sinh giỏi không làm mọi câu theo cùng một cách

Bối Cảnh Đầu Vào Đa Dạng

Đọc hiểu

Tự sự & Ngữ cảnh

STEM / Giải toán

Logic & Tính toán

Kiến thức chung

Truy xuất thông tin

Bẫy từ chối / An toàn

Bảo mật & Quy tắc

Không thể dùng một chiến lược duy nhất cho tất cả câu hỏi.

Nếu dùng một cấu trúc đơn giản:

→ **Một prompt không đủ cho mọi câu hỏi**

Prompt nhanh có thể yếu ở STEM; prompt suy luận dài lại làm chậm câu hỏi kiến thức đơn giản.

→ **Trả lời tự do dễ gây lỗi định dạng**

Mô hình có thể sinh giải thích, nhiều đáp án, hoặc ký tự không hợp lệ thay vì một chữ cái duy nhất.

→ **Private test lớn hơn public test**

Chỉ độ chính xác thôi là chưa đủ. Trên máy chấm bài, hệ thống phải xử lý được 2000 câu hỏi mà không bị lỗi, đồng thời cho phép chúng ta giải trình về việc tài nguyên tính toán đã được sử dụng như thế nào.

2. Kiến Trúc Cuối Cùng

Từ một câu hỏi đầu vào đến một đáp án hợp lệ



Ứng viên triển khai: v03_gamma

Final runner được chọn vì cân bằng tốt nhất giữa **85.96%** public score, tốc độ xử lý và độ ổn định trên GPU 16 GB. v03_delta đạt **87.04%** nhưng không được chọn do chậm hơn và rủi ro tràn bộ nhớ cao hơn.

Chiến lược an toàn bộ nhớ

Sử dụng cơ chế điều chỉnh linh hoạt theo bộ nhớ khả dụng, retry ladder theo mức headroom an toàn, chunked prefill, và chunk fallback theo từng wave khi phát hiện nguy cơ tràn bộ nhớ. Hệ thống luôn cố gắng xuất đủ file nộp theo định dạng qid,answer.

3. Cải Tiến Chủ Chốt

Các cải tiến giúp tăng điểm từ baseline (26.73%) lên final runner (85.96%)

Accuracy (Độ chính xác)

1. Định tuyến theo dạng câu hỏi

Chiến lược phù hợp cho từng câu thay vì dùng prompt tĩnh.

2. Suy luận nhiều lượt có mục tiêu

Tăng compute cho STEM và knowledge rủi ro cao.

3. Xử lý lựa chọn trùng lặp

Sửa lỗi vote khi nội dung giống nhau hoặc dạng tổ hợp.

4. Tráo lựa chọn

Giảm bias vị trí đáp án qua các lượt suy luận khác nhau.

Reliability (Độ tin cậy)

5. Lựa chọn đáp án có kiểm soát

Suy luận tự do nhưng kết quả bị ép về nhãn hợp lệ.

6. Bộ chạy luôn xuất file

Suy luận tự do nhưng kết quả bị ép về nhãn hợp lệ.

7. Tối ưu compute token theo từng câu

Theo dõi token, runtime và fallback để biết route nào tốn compute nhất và điều chỉnh dựa trên dữ liệu thực tế.

Speed & Safety (Tốc độ & An toàn)

8. Wave batching

Gom các lượt suy luận thành wave để tối ưu thời gian.

9. Cơ chế điều chỉnh VRAM linh hoạt

Runner đọc free VRAM rồi chọn `gpu_memory_utilization` phù hợp thay vì chỉ dùng giá định tĩnh.

10. Retry ladder

Nếu load hoặc wave gặp rủi ro, hệ thống thử lại với headroom an toàn hơn.

Cải tiến quan trọng nhất không phải thêm compute ở mọi nơi, mà là thêm compute đúng chỗ và không crash khi chạy trên dữ liệu lớn

4. Tiến Trình Đo Kết Quả

Vì sao chọn 85.96% thay vì 87.04%?

Phiên Bản	Bài học chính		Điểm Số
v01_baseline	Phân tích cú pháp dạng tự do quá yếu		28.73%
v02_alpha	Định tuyến & lựa chọn có hướng dẫn tạo bước nhảy lớn		60.48%
v02_beta	Suy luận thêm giúp câu khó, nhưng quá chậm		80.13%
v02_gamma	Wave batching giúp chiến lược mạnh trở nên thực tế		85.31%
v03_alpha	Bộ định tuyến sạch hơn nhưng mất tính toán cho kiến thức khó		84.23%
v03_gamma	Cân bằng tốt nhất giữa accuracy, runtime và độ ổn định		85.96%
v03_delta	Accuracy cao hơn nhưng chậm ~4x và rủi ro tràn bộ nhớ		87.04%

Quyết định cuối: v03_gamma được chọn làm bản cuối cùng vì phù hợp hơn khi chạy thành công tập dữ liệu tự tạo gồm 2000 câu hỏi của nhóm với độ chính xác 78.65% với khoảng 3.675s/câu

5. Hạn Chế & Sẵn Sàng Triển Khai

Trung thực về giới hạn. Chắc chắn về triển khai

Giới hạn đã biết

- Một số câu hỏi kiến thức ngách vẫn vượt quá năng lực của mô hình 4B.
- v03_gamma dùng tín hiệu confidence nhẹ, chưa phải exact real-margin đầy đủ như v03_delta.
- Self-consistency giúp tăng độ chính xác nhưng vẫn làm tăng thời gian chạy.
- Public set nhỏ hơn private set, nên luôn có rủi ro overfitting theo leaderboard.
- Không dùng RAG/fine-tuning/API để giữ đúng constraint và giảm rủi ro triển khai.

Cam kết triển khai

- Offline Docker inference, không cần internet.
- Một mô hình duy nhất: Qwen/Qwen3.5-4B.
- Đọc /code/private_test.json.
- Ghi /code/submission.csv và /code/submission_time.csv.
- Có checkpoint, fallback và always-emit runner để giảm nguy cơ submission lỗi.

“Nhanh với câu dễ. Cần trọng với câu khó. Bền bỉ khi triển khai ngoại tuyến.”

6. Kết Luận: VietMind MCQ Không Chỉ Là Một Prompt

Không phải câu hỏi nào cũng cần cùng một lượng suy luận

Hệ Thống VietMind MCQ

Hệ thống làm bài thi tối ưu hóa xoay quanh một mô hình ngôn ngữ lớn (LLM) nhỏ.

CẤU HÌNH XUẤT SẮC NHẤT

v03_gamma

Qwen/Qwen3.5-4B

85.96% public leaderboard

1

Lập luận thích ứng

Câu dễ trả lời nhanh; câu khó được cấp thêm suy luận.

2

Trả lời câu hỏi trắc nghiệm có kiểm soát

Mô hình được suy luận trước, nhưng đáp án cuối luôn bị ép về nhãn hợp lệ.

3

An toàn khi triển khai ngoại tuyến

Một LLM $\leq 5B$, không RAG/API/fine-tuning, cơ chế điều chỉnh VRAM linh hoạt, retry ladder giúp giảm rủi ro crash.

Báo Cáo Đầy Đủ & Nguồn Trích Dẫn

Báo cáo đầy đủ được lưu tại đây:

https://github.com/lqminhhh/hackaithon-innovator/blob/main/docs/report/report_vi.md

Các trích dẫn nghiên cứu dùng trong báo cáo:

- Jason Wei et al., 2022, Chain-of-Thought Prompting Elicits Reasoning in Large Language Models
- Xuezhi Wang et al., 2022, Self-Consistency Improves Chain of Thought Reasoning in Language Models
- Chujie Zheng et al., 2023, Large Language Models Are Not Robust Multiple Choice Selectors
- Woosuk Kwon et al., 2023, Efficient Memory Management for Large Language Model Serving with PagedAttention
- Shunyu Yao et al., 2023, Tree of Thoughts: Deliberate Problem Solving with Large Language Models

XIN CẢM ƠN!

Cảm ơn mọi người đã theo dõi bài thuyết trình!

Phụ Lục A: Kiểm Chứng Kết Quả và Quyết Định Nhánh Cuối

Vì sao giữ v03_gamma?

Các nhánh không được chọn:

- Nhóm đã thử chạy pipeline trên bộ khoảng 2000 câu tự dựng, tổng hợp từ các nguồn được phép sử dụng theo license, bao gồm Hugging Face, dữ liệu AI-generated, và Quizlet; mục tiêu chính là kiểm tra completion reliability, không phải tối ưu một điểm số nội bộ.
- **Fine-tuning** trên bộ này không mang lại lợi ích đủ rõ ở KNOWLEDGE, trong khi sai đi một phần câu STEM.
- **Instruct model** không khớp tốt với reasoning pipeline hiện tại, vốn được thiết kế quanh serving path và policy đang dùng.
- **AWQ 4-bit** cải thiện tốc độ phần nào nhưng giảm accuracy đáng kể.
- **GGUF + llama.cpp** không phù hợp với stack hiện tại vì sẽ đánh mất lợi thế của vLLM wave batching, prefix caching, chunked prefill, và throughput ở quy mô lớn.

Kết luận: Nhánh cuối được chọn theo trade-off triển khai tốt nhất cho run dài, không chỉ theo peak score.

Phụ Lục B: Chính Sách Suy Luận Theo Từng Nhóm Câu Hỏi

Router quyết định cách tiếp cận. Chính sách suy luận quyết định mức độ cần trọng

ĐỌC HIỂU



Tín hiệu

Có đoạn văn, hỏi chi tiết, mục đích, lí do

Cách xử lý

Bám sát đoạn văn; đọc lại khi câu hỏi yêu cầu chi tiết, mục đích hoặc lý do

Lý do

Đáp án đã nằm trong ngữ cảnh, không cần suy luận ngoài

STEM / GIẢI TOÁN



Tín hiệu

Công thức, số liệu, tính toán, logic

Cách xử lý

Luôn cập thêm suy luận và voting

Lý do

Một lỗi tính toán nhỏ có thể đổi đáp án

KIẾN THỨC CHUNG



Tín hiệu

Khái niệm, lựa chọn mơ hồ, đáp án tổ hợp

Cách xử lý

Câu dễ trả lời nhanh; câu rủi ro được escalation

Lý do

Mô hình 4B dễ sai ở kiến thức ngành hoặc lựa chọn gần nhau

BẦY TỬ CHỐI / AN TOÀN



Tín hiệu

Yêu cầu nguy hiểm + có phương án từ chối

Cách xử lý

Kiểm tra harmful intent và chọn từ chối khi phù hợp

Lý do

Tránh vừa trả lời nguy hiểm, vừa tránh từ chối sai câu học thuật

Phụ Lục C: Luồng Công Việc Đánh Giá

Không chỉ đo điểm – chúng tôi truy vết lý do hệ thống đúng hoặc sai



MINI TRACE CARD (Mẫu)

- Lựa chọn: **STEM / GIẢI TOÁN**
- Câu trả lời đầu: **A (Baseline)**
- Câu trả lời cuối: **C (Corrected)**
- Bỏ phiếu: **A, A, C, C, C**
- Biên độ tự tin: **0.89**
- Escalation Reason: "stem_sc_adaptive_n3"

Mỗi thay đổi phải trả lời một câu hỏi: nó sửa lỗi thật, hay chỉ làm pipeline phức tạp hơn?