

Vietnamese Student HackAlthon 2026 - Bảng C Innovator

VietMind MCQ

**AI Agent giải trắc nghiệm tiếng Việt
bằng suy luận thích ứng**

Đội Cow: Lê Quang Minh, Nguyễn Ngô Thảo Uyên, Nguyễn Minh Việt

Tóm Tắt Phương Pháp

85.96%

Kết quả public test, được kiểm chứng trên bảng xếp hạng công khai Vòng 1



Một mô hình mở duy nhất $\leq 5B$

Được vận hành bởi **Qwen/Qwen3.5-4B** mà không sử dụng RAG, API bên ngoài, hay kỹ thuật tinh chỉnh.



Lập luận thích ứng + chọn đáp án có kiểm soát

Mỗi câu hỏi được định tuyến theo nhóm; câu khó được suy luận nhiều lượt, sau đó hệ thống ép kết quả về một đáp án hợp lệ trước khi xuất file.



Docker Container Ngoại Tuyến

Thực thi khép kín, không phụ thuộc mạng, đảm bảo an toàn cho giới hạn nghiêm ngặt 16 GB VRAM.

1. Bài Toán và Nhận Định Chính

Không thể dùng một chiến lược cho mọi câu hỏi

Bối Cảnh Đầu Vào Đa Dạng

Đọc hiểu

Tự sự & Ngữ cảnh

STEM / Giải toán

Logic & Tính toán

Kiến thức chung

Truy xuất thông tin

Bẫy từ chối / An toàn

Bảo mật & Quy tắc

Không thể dùng một chiến lược duy nhất cho tất cả câu hỏi.

Ba vấn đề chính nếu dùng một pipeline đơn giản

→ **Một prompt không đủ cho mọi câu hỏi**

Prompt nhanh có thể yếu ở STEM; prompt suy luận dài lại làm chậm câu hỏi kiến thức đơn giản.

→ **Trả lời tự do dễ gây lỗi định dạng**

Mô hình có thể sinh giải thích, nhiều đáp án, hoặc ký tự không hợp lệ thay vì một chữ cái duy nhất.

→ **Private test lớn hơn public test**

Hệ thống phải ưu tiên khả năng chạy ổn định, checkpoint, fallback và kiểm soát VRAM.

2. Kiến Trúc Cuối Cùng

Từ một câu hỏi đầu vào đến một đáp án hợp lệ



Ứng viên triển khai: v03_gamma

Final runner được chọn vì cân bằng tốt nhất giữa **85.96%** public score, tốc độ xử lý và độ ổn định trên GPU 16 GB. v03_delta đạt **87.04%** nhưng không được chọn do chậm hơn và rủi ro tràn bộ nhớ cao hơn.

Chiến lược an toàn bộ nhớ

Dùng safe-mode, giới hạn batch/context, wave batching và checkpoint theo wave để giảm rủi ro hết bộ nhớ. Hệ thống luôn cố gắng xuất đủ file pred.csv theo định dạng qid,answer.

3. Chính Sách Suy Luận Theo Từng Nhóm Câu Hỏi

Router quyết định cách tiếp cận. Chính sách suy luận quyết định mức độ cần trọng

ĐỌC HIỂU



Cách xử lý

Bám sát đoạn văn; đọc lại khi câu hỏi yêu cầu chi tiết, mục đích hoặc lý do

Lý do

Đáp án đã nằm trong ngữ cảnh, không cần suy luận ngoài

STEM / GIẢI TOÁN



Cách xử lý

Luôn dùng suy luận nhiều lượt và bình chọn

Lý do

Giảm lỗi tính toán, lỗi logic và sai sót trong câu nhiều lựa chọn

KIẾN THỨC CHUNG



Cách xử lý

Tăng thêm compute cho câu nhiều lựa chọn, lựa chọn mở hồ hoặc dạng tổ hợp

Lý do

Đây là nhóm dễ sai do giới hạn kiến thức của mô hình 4B

BẦY TỬ CHỐI / AN TOÀN



Cách xử lý

Kiểm tra harmful intent; nếu có phương án từ chối phù hợp thì ép chọn từ chối

Lý do

Tránh vừa trả lời nội dung nguy hiểm, vừa tránh từ chối sai câu hỏi học thuật

4. Cải Tiến Chủ Chốt

Các cải tiến giúp tăng điểm từ baseline lên final runner

Accuracy (Độ chính xác)

1. Định tuyến theo dạng câu hỏi

Chiến lược phù hợp cho từng câu thay vì dùng prompt tĩnh.

2. Suy luận nhiều lượt có mục tiêu

Tăng compute cho STEM và knowledge rủi ro cao.

3. Xử lý lựa chọn trùng lặp

Sửa lỗi vote khi nội dung giống nhau hoặc dạng tổ hợp.

4. Tráo lựa chọn

Giảm bias vị trí đáp án qua các lượt suy luận khác nhau.

Reliability (Độ tin cậy)

5. Lựa chọn đáp án có kiểm soát

Suy luận tự do nhưng kết quả bị ép về nhãn hợp lệ.

6. Bộ chạy luôn xuất file

Đảm bảo xuất file hoàn chỉnh ngay cả khi gặp lỗi hệ thống.

Speed & Safety (Tốc độ & An toàn)

7. Wave batching

Gom các lượt suy luận thành wave để tối ưu thời gian.

8. Nhận thức về quá trình thực thi

Thiết kế phù hợp với giới hạn 16GB VRAM nghiêm ngặt.

5. Luồng Công Việc Đánh Giá

Không chỉ đo điểm – chúng tôi truy vết lý do hệ thống đúng hoặc sai



MINI TRACE CARD (Mẫu)

- Lựa chọn: **STEM / GIẢI TOÁN**
- Câu trả lời đầu: **A (Baseline)**
- Câu trả lời cuối: **C (Corrected)**
- Bỏ phiếu: **A, A, C, C, C**
- Biên độ tự tin: **0.89**
- Escalation Reason: "stem_sc_adaptive_n3"

Mỗi thay đổi đều được kiểm chứng bằng leaderboard, trace log và phân tích hồi quy.

6. Tiến Trình Kết Quả

Từ baseline tự do đến pipeline suy luận thích ứng

Phiên Bản	Bài học chính		Điểm Số
v01_baseline	Phân tích cú pháp dạng tự do quá yếu		28.73%
v02_alpha	Định tuyến & lựa chọn có hướng dẫn tạo bước nhảy lớn		60.48%
v02_beta	Suy luận thêm giúp câu khó, nhưng quá chậm		80.13%
v02_gamma	Wave batching giúp chiến lược mạnh trở nên thực tế		85.31%
v03_alpha	Bộ định tuyến sạch hơn nhưng mất tính toán cho kiến thức khó		84.23%
v03_gamma	Cân bằng tốt nhất giữa accuracy, runtime và độ ổn định		85.96%
v03_delta	Accuracy cao hơn nhưng chậm ~4x và rủi ro tràn bộ nhớ		87.04%

Quyết định cuối: v03_gamma được chọn làm final runner vì phù hợp hơn với private test ~2000 câu trên GPU 16 GB: đủ mạnh, nhanh hơn nhiều so với v03_delta, và ít rủi ro lỗi bộ nhớ hơn.

7. Hạn Chế & Sẵn Sàng Triển Khai

Nhanh với câu dễ. Cẩn trọng với câu khó. Bền bỉ khi triển khai ngoại tuyến.

Hạn chế hiện tại

- Một số câu hỏi kiến thức ngách vẫn vượt quá năng lực của mô hình 4B.
- v03_gamma dùng tín hiệu confidence nhẹ, chưa phải exact real-margin đầy đủ như v03_delta.
- Self-consistency giúp tăng độ chính xác nhưng vẫn làm tăng runtime.
- Public set nhỏ hơn private set, nên luôn có rủi ro overfitting theo leaderboard.
- Không dùng RAG/fine-tuning/API để giữ đúng constraint và giảm rủi ro triển khai.

Sẵn sàng triển khai

- Offline Docker inference, không cần internet.
- Một mô hình duy nhất: Qwen/Qwen3.5-4B.
- Đọc /data/public_test.csv hoặc /data/private_test.csv.
- Xuất /output/pred.csv đúng định dạng qid,answer.
- Có checkpoint, fallback và always-emit runner để giảm nguy cơ submission lỗi.
- Safe-mode cho GPU 16 GB.

“Nhanh với câu dễ. Cẩn trọng với câu khó. Bền bỉ khi triển khai ngoại tuyến.”

Nguồn Trích Dẫn

Các trích dẫn nghiên cứu dùng trong báo cáo:

- Jason Wei et al., 2022, Chain-of-Thought Prompting Elicits Reasoning in Large Language Models
- Xuezhi Wang et al., 2022, Self-Consistency Improves Chain of Thought Reasoning in Language Models
- Chujie Zheng et al., 2023, Large Language Models Are Not Robust Multiple Choice Selectors
- Woosuk Kwon et al., 2023, Efficient Memory Management for Large Language Model Serving with PagedAttention
- Shunyu Yao et al., 2023, Tree of Thoughts: Deliberate Problem Solving with Large Language Models